Τεχνικές Βελτιστοποίησης
Project Εξαμήνου
Γενετικοί Αλγόριθμοι

Χριστίνα Τσακλόγλου ΑΕΜ: XXXXX
Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών, ΑΠΘ

1 Απριλίου 2026

Περιεχόμενα

1 Εισαγωγή **2**

2 Θεωρία Γενετικών Αλγορίθμων **2**

3 Θεωρία Gaussian Συναρτήσεων **2**

4 Ανάλυση Προβλήματος **3**

5 Υλοποίηση **3**
5.1 Γραφική παράσταση της συνάρτησης f . . . 3
5.2 Αρχικοποίηση Συναρτήσεων . . . 3
5.3 Δημιουργία Training Data . . . 4
5.4 Υπολογισμός του συνολικού σφάλματος root square error για κάθε γραμμικό συνδυασμό του πληθυσμού . . . 4
5.5 Γενετικός Αγλόριθμος - Ελαχιστοποίηση συνολικού σφάλματος . . . 4
5.5.1 Ελιτισμός . . . 5
5.5.2 Επιλογή – Tournament Selection . . . 5
5.5.3 Crossover . . . 6
5.5.4 Mutation . . . 7
5.6 Τερματική Συνθήκη . . . 7
5.7 Οπτικοποίηση Βέλτιστης Προσέγγισης . . . 7
5.8 Αξιολόγηση της Βέλτιστης Προσέγγισης σε Ευρύτερο Σύνολο Εισόδων . . . 9

6 Συμπεράσματα **11**

7 Βιβλιογραφία **12**

1 Εισαγωγή

Στις προηγούμενες εργασίες του μαθήματος Τεχνικών Βελτιστοποίησης, καλούμασταν μέσω δοσμένων συναρτήσεων και μεθόδων που είχαμε αναλύσει εντός του μαθήματος να προσεγγίσουμε διάφορα χαρακτηριστικά σημεία (π.χ. ελάχιστο). Στις εν λόγω μεθόδους έπαιζαν ρόλο οι περιορισμοί των συναρτήσεων, το αρχικό σημείο, το πλήθος των επαναλήψεων, οι τερματικές συνθήκες κ.λπ.
Στο παρόν project, αντιθέτως, καλούμαστε να προσδιορίσουμε την αναλυτική έκφραση μιας άγνωστης συνάρτησης, κάνοντας χρήση γενετικών αλγορίθμων, τους οποίους θα υλοποιήσουμε βάσει έρευνας σε σχετική βιβλιογραφία.

2 Θεωρία Γενετικών Αλγορίθμων

Οι γενετικοί αλγόριθμοι (Genetic Algorithms) αποτελούν τεχνική βελτιστοποίησης εμπνευσμένη από τη διαδικασία της φυσικής επιλογής και της εξέλιξης. Αναπτύχθηκαν για πρώτη φορά από τον John Holland στη δεκαετία του 1960 και χρησιμοποιούνται ευρέως για την επίλυση σύνθετων προβλημάτων βελτιστοποίησης, τα οποία με παραδοσιακές μεθόδους θα απαιτούσαν απαγορευτικό υπολογιστικό χρόνο, χαρακτηριστικό παράδειγμα αξιοποίησης τους αποτελεί ο τομέας της μηχανικής μάθησης.
Όπως στη φύση οι οργανισμοί κληρονομούν χαρακτηριστικά από γενιά σε γενιά μέσω γενετικών μηχανισμών (πχ. DNA), έτσι και στους γενετικούς αλγορίθμους οι λύσεις ενός προβλήματος εξελίσσονται μέσα από την εφαρμογή γενετικών τελεστών (selection, crossover, mutation). Η διαδικασία αυτή οδηγεί σταδιακά στην εξαφάνιση των κακών λύσεων και στη ενίσχυση των καλών, καταλήγοντας σε βέλτιστες ή σχεδόν βέλτιστες λύσεις.
Μερικά από τα πλεονεκτήματα των γενετικών αλγορίθμων είναι ότι δεν απαιτούν υπολογισμό παραγώγων ή προηγούμενη γνώση της συνάρτησης στόχου. Δε περιορίζονται σε μια καλή λύση αλλά περάχουν πληροφορίες για ένα σύνολο βελτιστοποιημένων και μη λύσεων. Εμφανίζουν καλύτερη απόδοση ειδικά όταν το πρόβλημα περιλαμβάνει μεγάλο πλήθος παραμέτρων εισόδου και συνεπώς μεγάλο χώρο αναζήτησης.

3 Θεωρία Gaussian Συναρτήσεων

Η προσέγγιση της επιθυμητής συνάρτησης θα πραγματοποιηθεί με τη χρήση γραμμικού συνδυασμού Gaussian συναρτήσεων.
Η γενική μορφή μιας γκαουσιανής συνάρτησης είναι:

$$G(x) = ae^{-\frac{(x-b)^2}{2\sigma^2}}$$

Η γραφική της παράσταση είναι μια καμπύλη με μορφή καμπάνας, που έχει κέντρο στο $x = b$, στο οποίο η συνάρτηση παίρνει τη μέγιστη τιμή $f(b) = a$. Το b αποτελεί τη μέση τιμή της συνάρτησης, ενώ το σ^2 προσδιορίζει το πλάτος της καμπύλης, δηλαδή το οξύ ή πεπλατυσμένο του σχήματός της.
Ένας γραμμικός συνδυασμός γκαουσιανών συναρτήσεων ($\sum w_i G_i$) περιλαμβάνει το άθροισμα πολλαπλών γκαουσιανών καμπύλων, καθεμία από τις οποίες πολλαπλασιάζεται με έναν συντελεστή βαρύτητας (w_i), προκειμένου να δημιουργηθούν πιο σύνθετες συναρτήσεις που μπορούν να αναπαραστήσουν ποικίλα σχήματα.

4 Ανάλυση Προβλήματος

Θεωρούμε μια συνάρτηση $f(u_1, u_2)$, δύο εισόδων και μιας εξόδου, της οποίας την αναλυτική έκφραση δε γνωρίζουμε. Προκειμένου να προσδιοριστεί μια αναλυτική έκφραση, χρησιμοποιούμε κατάλληλα σχεδιασμένο γραμμικό συνδυασμό γκαουσιανών συναρτήσεων της μορφής:

$$G(u_1, u_2) = e^{-(\frac{(u_1-c_1)^2}{2\sigma_1^2}+\frac{(u_2-c_2)^2}{2\sigma_2^2})}$$

Όπως αναφέραμε νωρίτερα, ο γενετικός αλγόριθμος έχει καλύτερη απόδοση όταν έχουμε πολλές μεταβλητές, για να εξετάσουμε έτσι διαφορετικό εύρος τιμών εισόδου-εξόδου. Για την υλοποίηση του προβλήματός μας θα θεωρήσουμε ότι έχουμε γραμμικό συνδυασμό 15 γκαουσιανών συναρτήσεων, δηλαδή:

$$\sum_{i=1}^{15} = w_i G_i(u_1, u_2)$$

Επίσης για να αξιολογήσουμε τα αποτελέσματα του γενετικού αλγόριθμου και της προσέγγισής μας, θεωρούμε ότι:

$$f(u_1, u_2) = \sin(u_1 + u_2)\sin(u_2^2)$$

με $u_1 \in [-1, 2]$ & $u_2 \in [-2, 1]$.
Σκοπός του προβλήματος είναι να βρούμε μια προσέγγισης της f στο σύνολο εισόδου u_1, u_2 αλλά να επιβεβαιώσουμε την ακρίβεια του αλγορίθμου με ένα ευρύτερο σύνολο εισόδου.

5 Υλοποίηση

5.1 Γραφική παράσταση της συνάρτησης f

Αρχικά, σχεδίαζουμε την τρισδιάστατη γραφική παράσταση της συνάρτησης f ως προς τις μεταβλητές u_1 και u_2, ώστε να αποκτήσουμε μια κατανοητή εικόνα της συμπεριφοράς της.

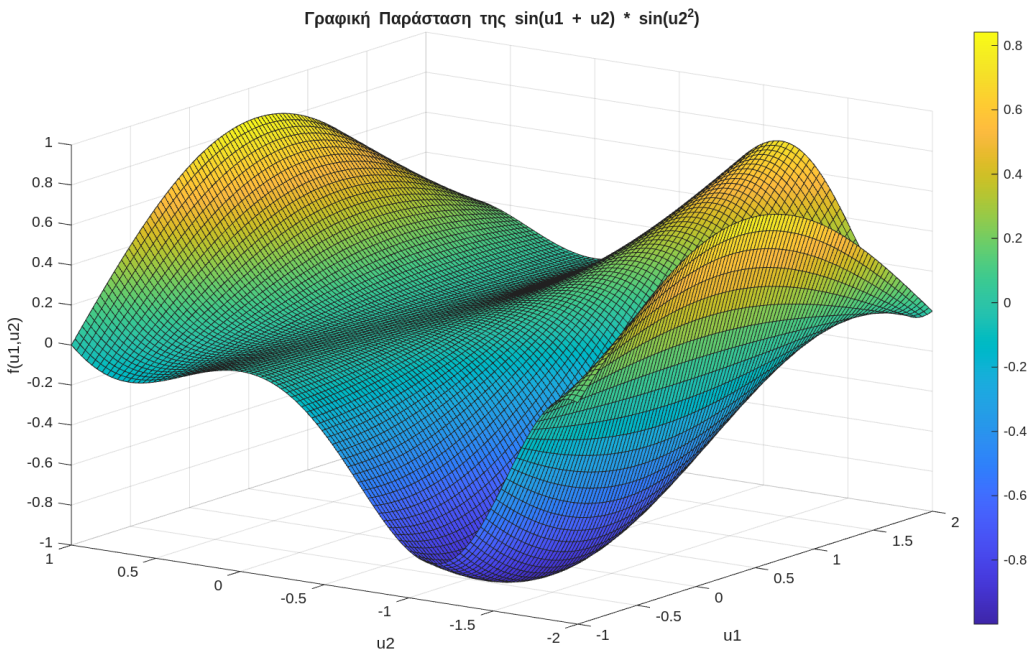

Σχήμα 1: Διάγραμμα αναλυτικής συνάρτησης f για δοσμένο εύρος εισόδου

5.2 Αρχικοποίηση Συναρτήσεων

Κάθε γραμμικός συνδυασμός αποτελείται από 15 συναρτήσεις G, εκ των οποίων η κάθε μια χαρακτηρίζεται από τις 5 μεταβλητές $w, c_1, c_2, \sigma_1, \sigma_2$, συνεπώς αν εισάγουμε σε ένα διάνυσμα γραμμή όλες τις αναγκαίες μεταβλητές για να εκφραστεί ο γραμμικός συνδυασμός, θα χρειαζόμασταν 15 * 5 = 75 θέσεις.

Ταυτόχρονα για την υλοποίηση του γενετικού αλγορίθμου χρειαζόμαστε ένα μεγάλο πλήθος συναρτήεων για να πειραματιστούμε και να βρούμε τη βέλτιστη λύση, στη περίπτωσή μας επιλέγουμε 50 τέτοιες συναρτήσεις.
Συνεπώς, κάνουμε pre-allocate χώρο στη μνήμη και ορίζουμε ένα πίνακα μηδενικών με μέγεθος [75][50], στον οποίο εισάγονται τυχαία μεταβλητές περιορισμένες από όρια που επιλέγουμε εμείς, με τη μορφή:

$$[w_1, c_{11}, c_{12}, \sigma_{11}, \sigma_{12}, w_2, c_{21}, c_{22}, \sigma_{21}, \sigma_{22}, ...]$$

Οι παράμετροι ορίστηκαν με συγκεκριμένα όρια τιμών: το βάρος/w παίρνει τιμές από -3 έως 3, η παράμετρος c_1 από -1 έως 2, η c_2 από -1 έως 2, ενώ οι παράμετροι σ_1 και σ_2 περιορίζονται στο διάστημα από 0.2 έως 1.5. Αυτά τα όρια διασφαλίζουν ότι οι τιμές παραμένουν σε λογικά και αποδεκτά πλαίσια.

5.3 Δημιουργία Training Data

Στο γενετικό αλγόριθμο μας απασχολεί η απόκλιση της τιμής της συνάρτησης f από τη προσέγγισή μας, για ένα μεγάλο σύνολο σημείων u_1, u_2, επομένως χρειάζεται να αρχικοποιήσουμε Training δεδομένα. Για αυτό το λόγο, κάνουμε pre allocate στη μνήμη ένα πίνακα μεγέθους [N_train][3], όπου έστω N_train =100. Γίνεται generate τιμών για τις μεταβλητές εισόδου u_1, u_2 εντός των αποδεκτών ορίων και υπολογίζουμε τη τιμή της f στο σημείο αυτό. Έτσι τα δεδομένα καταχωρούνται με τη μορφή $[u_1, u_2, f(u_1, u_2)]$.

5.4 Υπολογισμός του συνολικού σφάλματος root square error για κάθε γραμμικό συνδυασμό του πληθυσμού

Για να υπολογίσουμε τη βέλτιστη γκαουσιανή, σκοπός μας είναι να ελαχιστοποιήσουμε την απόκλιση μεταξύ της πραγματικής τιμής της f και της προσέγγισής μας συσσωρευτικά σε όλα τα στοιχεία του Training Data. Αυτό πραγματοποιείται με τον εξής τρόπο:

- Μπαίνουμε σε μια λούπα που διατρέχει όλους τους γραμμικούς συνδυασμούς γκαουσιανών του πληθυσμού μας
  - Μπαίνουμε σε μια λούπα που διατρέχει όλα τα σημεία του Training Data
    1. Για κάθε στοιχείο του Training Data ανακτούμε τις τιμές $u_1, u_2, f(u_1, u_2)$.
    2. Για το εκάστοτε σημείο $[u_1, u_2]$ υπολογίζουμε την τιμή κάθε γκαουσιανής συνάρτησης G (15 φορές για διαφορετικά $w, c_1, c_2, \sigma_1, \sigma_2$) και προκύπτει η προβλεπόμενη τιμή του γραμμικού συνδυασμού.
    3. Υπολογίζουμε το τετράγωνο της διαφοράς μεταξύ της πραγματικής τιμής $f(u_1, u_2)$ και της προβλεπόμενης τιμής και το προσθέτουμε στο συνολικό άθροισμα σφαλμάτων.
  - Αφού διατρέξουμε όλα τα σημεία, έχουμε υπολογίσει το συνολικό άθροισμα τετραγώνων σφαλμάτων, το οποίο διαιρούμε με το N_train και λαμβάνουμε την τετραγωνική ρίζα.
- Το αποτέλεσμα αυτό αντιστοιχεί στο συνολικό RMS error του γραμμικού συνδυασμού γκαουσιανών στο σύνολο των Training Data, το οποίο καταχωρίζεται σε πίνακα για κάθε συνάρτηση του πληθυσμού.

5.5 Γενετικός Αγλόριθμος - Ελαχιστοποίηση συνολικού σφάλματος

Σε αυτό το σημείο του προγράμματος έχουμε υπολογίσει το συνολικό σφάλμα για όλα τα δείγματα του πληθυσμού. Καθώς ο αλγόριθμος εκτελείται επαναληπτικά, στόχος μας είναι το σφάλμα να μειώνεται. Για τον λόγο αυτό κρατάμε τις καλύτερες λύσεις και τις συνδυάζουμε μεταξύ τους.

5.5.1 Ελιτισμός

Σε κάθε επανάληψη εντοπίζεται ο γραμμικός συνδυασμός που παρουσιάζει το ελάχιστο συνολικό σφάλμα και αποθηκεύονται σε ένα προσωρινό διάνυσμα όλοι οι συντελεστές του. Αφού εφαρμοστούν οι γενετικοί τελεστές που περιγράφονται παρακάτω και προκύψει ένας νέος πίνακας δεδομένων $[50, 75]$, η πρώτη γραμμή του πίνακα αντικαθίσταται από το διάνυσμα αυτό. Με τον τρόπο αυτό μεταδίδεται από γενιά σε γενιά ο καλύτερος γραμμικός συνδυασμός, διαδικασία που είναι γνωστή ως ελιτισμός.

5.5.2 Επιλογή – Tournament Selection

Στο στάδιο αυτό επιλέγονται τυχαία ορισμένοι γραμμικοί συνδυασμοί του πληθυσμού, τόσο με μικρό όσο και με αυξημένο RMS Error, με σκοπό τη δημιουργία ενός αντιπροσωπευτικού αλλά «ισχυρού» δείγματος. Οι επιλεγμένες τιμές καταχωρούνται στη συνέχεια σε έναν νέο πίνακα ίδιων διαστάσεων με τον αρχικό, $[50, 75]$.

Ειδικότερα:

1. Αρχικοποιούμε έναν πίνακα μηδενικών διαστάσεων $[50, 75]$.
2. Παράγουμε τρεις τυχαίους ακέραιους αριθμούς στο διάστημα $[01, 75]$ και επιλέγουμε τους αντίστοιχους γραμμικούς συνδυασμούς γκαουσιανών.
3. Εντοπίζουμε, από τον σχετικό πίνακα, το συνολικό σφάλμα που αντιστοιχεί σε κάθε γραμμικό συνδυασμό.
4. Συγκρίνουμε τα σφάλματα αυτά και επιλέγουμε τον γραμμικό συνδυασμό με το μικρότερο συνολικό σφάλμα.
5. Τοποθετούμε τον επιλεγμένο γραμμικό συνδυασμό στη θέση που αντιστοιχεί στην τρέχουσα γραμμή του νέου πίνακα.
6. Επαναλαμβάνουμε τη διαδικασία για όλο τον πληθυσμό, δηλαδή συνολικά 50 φορές.

Η συγκεκριμένη μέθοδος δεν περιορίζει την επιλογή ενός διανύσματος με μικρό σφάλμα περισσότερες από μία φορές, καθώς βασίζεται στην τυχαία παραγωγή αριθμών. Παράλληλα, η μέθοδος Tournament Selection παραμένει αμερόληπτη ως προς δείγματα με μεγαλύτερο σφάλμα.

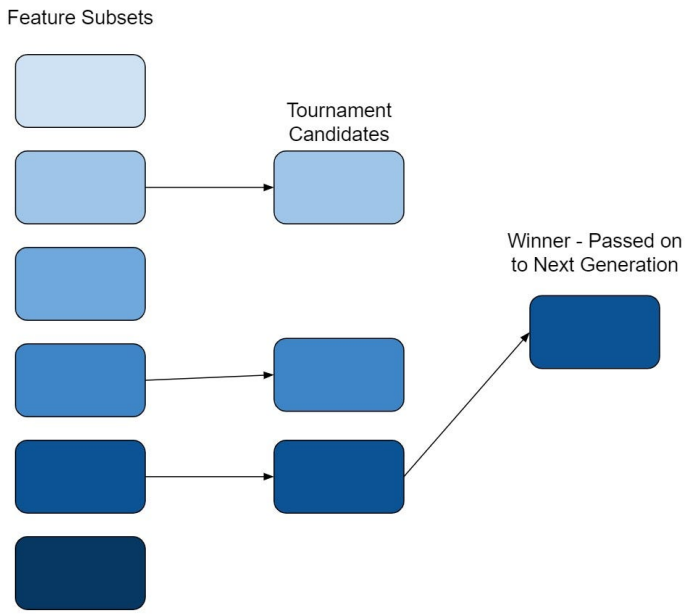

Σχήμα 2: Σχηματική απεικόνιση της μεθόδου Tournament Selection

5.5.3 Crossover

Λαμβάνουμε τον τροποποιημένο πίνακα από το Tournament Selection και ¨αναμειγνύουμε¨ τα δεδομένα μας, προκειμένου να σχηματιστούν νέοι γραμμικοί συνδυασμοί προς έλεγχο. Συγκεκριμένα:

1. Διατρέχουμε τον πίνακα γραμμικών συνδυασμών μεγέθους $[50, 75]$ με βήμα δύο. Οι γραμμικοί συνδυασμοί είναι ήδη τυχαία τοποθετημένοι, γι' αυτό επιλέγουμε να αναμείξουμε τους «γείτονες».

2. Παράγουμε έναν τυχαίο αριθμό στο διάστημα $[1, 75]$, ο οποίος θα αποτελέσει το breaking_point του διανύσματός μας.

3. Παίρνουμε τα στοιχεία του πρώτου διανύσματος από το 1 μέχρι το breaking_point και τα στοιχεία του δεύτερου διανύσματος από το breaking_point μέχρι το τέλος του διανύσματος, δημιουργώντας έναν νέο γραμμικό συνδυασμό.

4. Τοποθετούμε τον νέο γραμμικό συνδυασμό στη θέση που αντιστοιχεί στην τρέχουσα γραμμή του νέου πίνακα.

5. Επαναλαμβάνουμε τη διαδικασία για όλο τον πληθυσμό, δηλαδή συνολικά 50 φορές.

6. Στην περίπτωσή μας έχουμε άρτιο αριθμό δειγμάτων και άρα «τέλειο» συνδυασμό διανυσμάτων. Σε διαφορετική περίπτωση, όπου περισσεύει ο τελευταίος γραμμικός συνδυασμός, εφαρμόζουμε κυκλικό crossover, δηλαδή αναμειγνύουμε το τελευταίο διάνυσμα με το πρώτο του πίνακα.

Σχόλιο: *Εναλλακτικά, θα μπορούσαμε να υπολογίσουμε και τα δύο δυνατά διανύσματα ανάμειξης. Στο πρώτο διάνυσμα λαμβάνουμε τα στοιχεία του πρώτου διανύσματος από το 1 έως το breaking_point και τα στοιχεία του δεύτερου διανύσματος από το breaking_point έως το τέλος του διανύσματος. Στο δεύτερο διάνυσμα ακολουθούμε την αντίστροφη διαδικασία. Στη συνέχεια, υπολογίζουμε το RMS Error για κάθε περίπτωση και επιλέγουμε τον βέλτιστο συνδυασμό, δηλαδή αυτόν με το μικρότερο σφάλμα. Και οι δύο προσεγγίσεις αποτελούν έγκυρες μορφές crossover.*

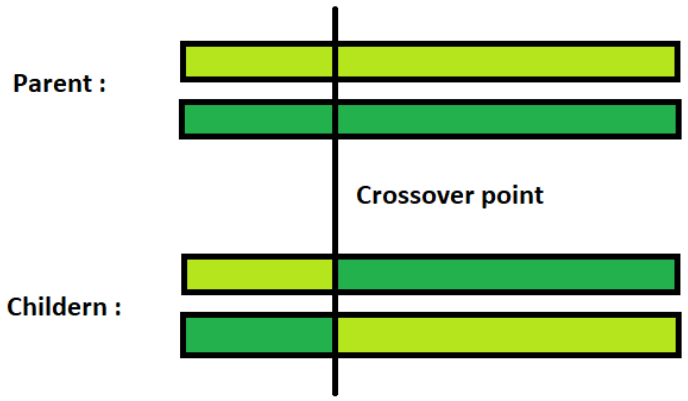

Σχήμα 3: Single-point crossover: Ανταλλαγή γενετικού υλικού μεταξύ δύο γονέων.

5.5.4 Mutation

Αν και ο πίνακας πλέον είναι τροποποιημένος-αναμειγμένος, είναι χρήσιμο να δοκιμάσουμε και άλλες τιμές στη θέση των συντελεστών, όχι όμως με μαζικό τρόπο. Για αυτό, σε ορισμένες μεταβλητές του διανύσματος εισάγουμε θόρυβο και τις τροποποιούμε.
Συγκεκριμένα:

1. Διατρέχουμε κάθε γραμμικό συνδυασμό του «πειραγμένου» πίνακα.
2. Εξετάζουμε μεμονωμένα κάθε γκαουσιανή του γραμμικού συνδυασμού.
3. Για κάθε στοιχείο της γκαουσιανής $(w, c_1, c_2, \sigma_1, \sigma_2)$ παράγουμε μια τυχαία πιθανότητα P και, αν και μόνο αν $P < 0.1$, τροποποιούμε την τιμή του στοιχείου.
4. Η νέα τιμή που ανατίθεται περιορίζεται εντός των αποδεκτών ορίων που ορίσαμε στην αρχή του προβλήματός μας.

Η διαδικασία της μετάλλαξης υλοποιήθηκε σε επίπεδο γονιδίου. Για κάθε μία από τις 75 παραμέτρους του χρωμοσώματος (βάρη, κέντρα και διασπορές των 15 γκαουσιανών), εξετάζεται ανεξάρτητα αν θα υποστεί μεταβολή με βάση την πιθανότητα μετάλλαξης (P_m). Στην περίπτωση μετάλλαξης, προστίθεται στο γονίδιο τυχαίος θόρυβος (Gaussian noise) ανάλογος του εύρους της παραμέτρου, ενώ ακολουθεί έλεγχος ορίων (clamping) για τη διατήρηση των τιμών εντός των επιτρεπτών διαστημάτων.

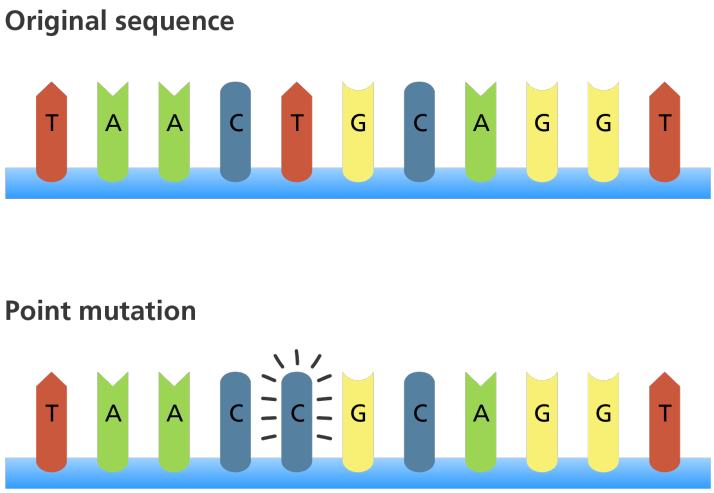

Σχήμα 4: Point mutation: Τυχαία αλλαγή μιας τιμής στο χρωμόσωμα.

Στο τελικό πίνακα εφαρμόζουμε τη μέθοδο του Ελιτισμού που αναφέραμε παραπάνω, τροποποιώντας συνεπώς το πρωτο διάνυσμα του πίνακά μας.

5.6 Τερματική Συνθήκη

Ο αλγόριθμός μας επαναλαμβάνεται έως ότου:

- Η ελάχιστη τιμή του πίνακα σφαλμάτων να είναι μικρότερη του 0.1, $min(final_error) < 0.1$.
- Ή μέχρι το πλήθος των επαναλήψεων/γενιών εφαρμογής του γενετικού αλγορίθμου να ξεπεράσει τις 900.

5.7 Οπτικοποίηση Βέλτιστης Προσέγγισης

Μόλις η μέθοδος τερματίσει, εντοπίζουμε τη βέλτιστη προσέγγιση αντιστοιχίζοντας τον δείκτη του ελάχιστου στοιχείου του πίνακα συνολικού σφάλματος στον αντίστοιχο γραμμικό συνδυασμό του τελικού πίνακα γκαουσιανών.

Στη συνέχεια, διατρέχουμε τον χώρο (u_1, u_2) για το σύνολο των σημείων που μας δίνεται και καλούμε τη σχετική συνάρτηση, η οποία υπολογίζει την τιμή των γκαουσιανών και επιστρέφει το συσσωρευτικό αποτέλεσμα.
Το τελικό αποτέλεσμα απεικονίζεται στην παρακάτω γραφική παράσταση.
Στην ίδια επανάληψη, και για τα ίδια δεδομένα, οπτικοποιούμε το τρισδιάστατο διάγραμμα της απόλυτης τιμής της διαφοράς μεταξύ της πραγματικής τιμής της f και της προσέγγισης, $error = |f(u_1, u_2) - f_{\text{estimation}}|$.

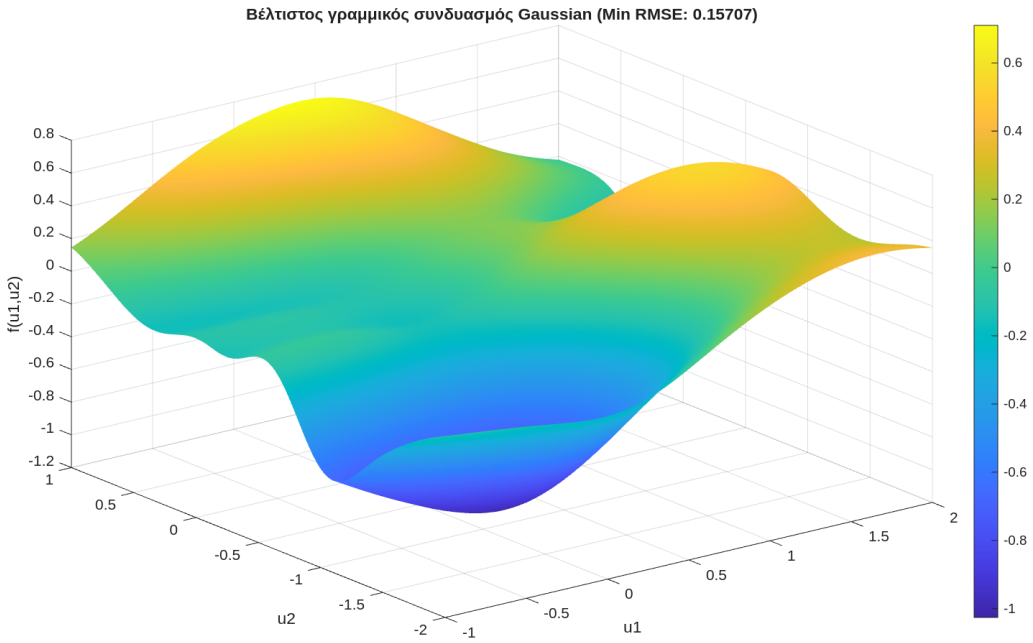

Σχήμα 5: Βέλτιστη προσέγγιση αναλυτικής μορφής f

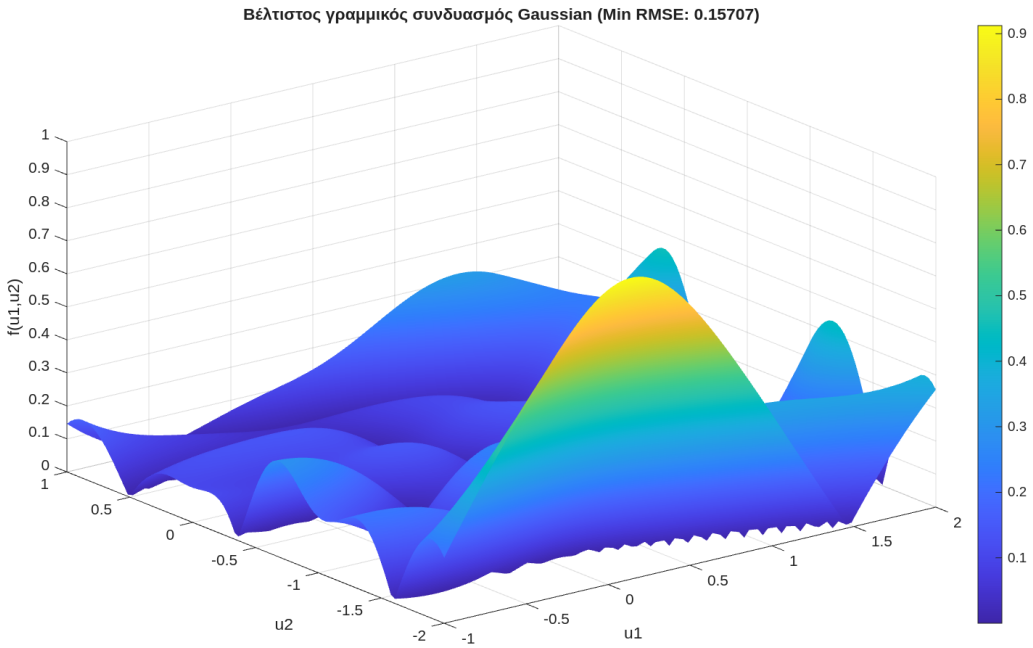

Σχήμα 6: Απόκλιση τιμής βέλτιστης προσέγγισης και πραγματικής τιμής f

Όπως παρατηρούμε, η απόκλιση μεταξύ των δύο τιμών κυμαίνεται στο διάστημα $[0, 0.9]$. Αυτό δείχνει ότι το σφάλμα που προκύπτει από τη χρήση του γενετικού αλγορίθμου παραμένει σχετικά μικρό και, επομένως, μπορούμε να πούμε ότι η προσέγγισή μας είναι ικανοποιητική και έγκυρη για το εύρος τιμών στο οποίο εκπαιδεύτηκε.
Το εύρος των τιμών απόκλισης και η κατανομή τους στο χώρο είναι καθαρά τυχαία και διαφοροποιείτε ανάλογα το πλήθος των επαναλήψεων, το min(error) που ορίζουμε, τα Training

Data που ορίζονται επίσης τυχαία και άλλους μη ντετερμινιστικούς παράγοντες.

5.8 Αξιολόγηση της Βέλτιστης Προσέγγισης σε Ευρύτερο Σύνολο Εισόδων

Για την αξιολόγηση της απόδοσης του γενετικού αλγορίθμου εκτός των δεδομένων εκπαίδευσης (Training Data), αντί να γράψουμε επιπλέον κώδικα ή να δημιουργήσουμε νέο validation set, τροποποιήσαμε προσωρινά τις τιμές των παραμέτρων εισόδου μόνο στο συγκεκριμένο section που αφορά την οπτικοποίηση:

$$\texttt{u1_range_test} = [-4, 4], \quad \texttt{u2_range_test} = [-5, 5]$$

Με αυτόν τον τρόπο μπορούμε να:

1. Απεικονίσουμε τη συνάρτηση f σε μεγαλύτερο εύρος εισόδου.
2. Απεικονίσουμε τη βέλτιστη προσέγγιση της f σε αυτό το μεγαλύτερο εύρος.
3. Δείξουμε την απόκλιση μεταξύ της βέλτιστης προσέγγισης και της πραγματικής συνάρτησης f (σε side και top view).

Σημειώνεται ότι οι υπολογισμένες παράμετροι της βέλτιστης προσέγγισης προέρχονται από το πρώτο section με τα δεδομένα εκπαίδευσης και δεν τροποποιήθηκαν για το συγκεκριμένο section.
Προκύπτουν οι εξής γραφικές παραστάσεις:

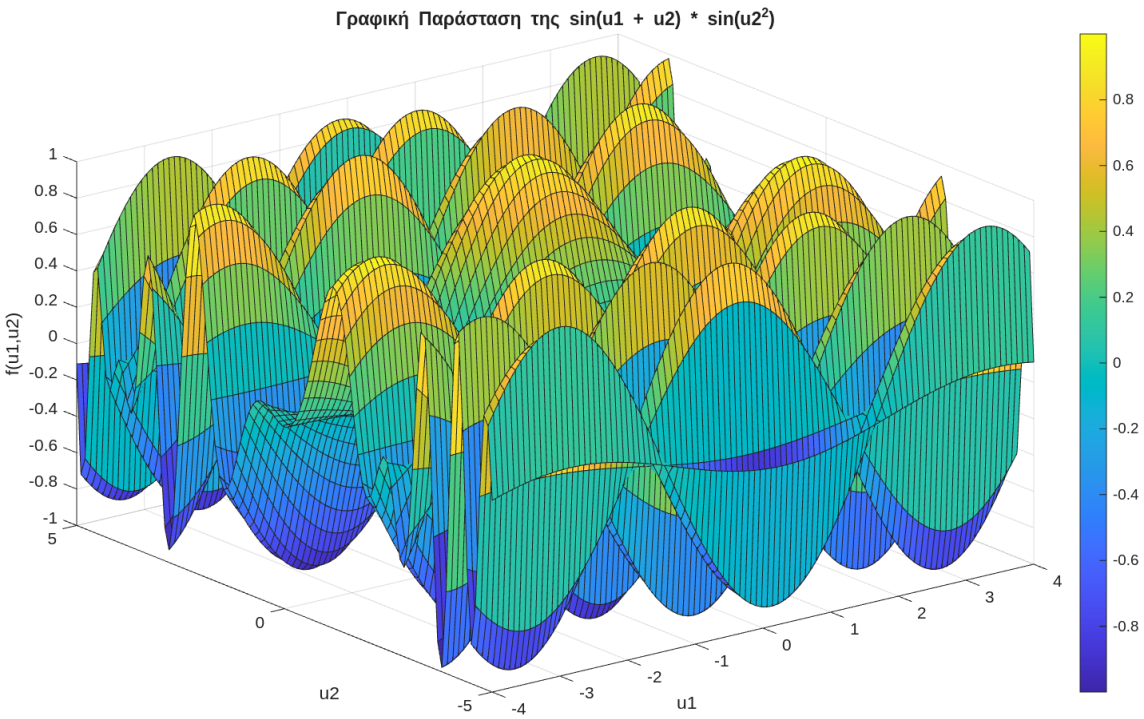

Σχήμα 7: Γραφική παράσταση της f σε σύνολο εισόδου μεγαλύτερο του Training Data

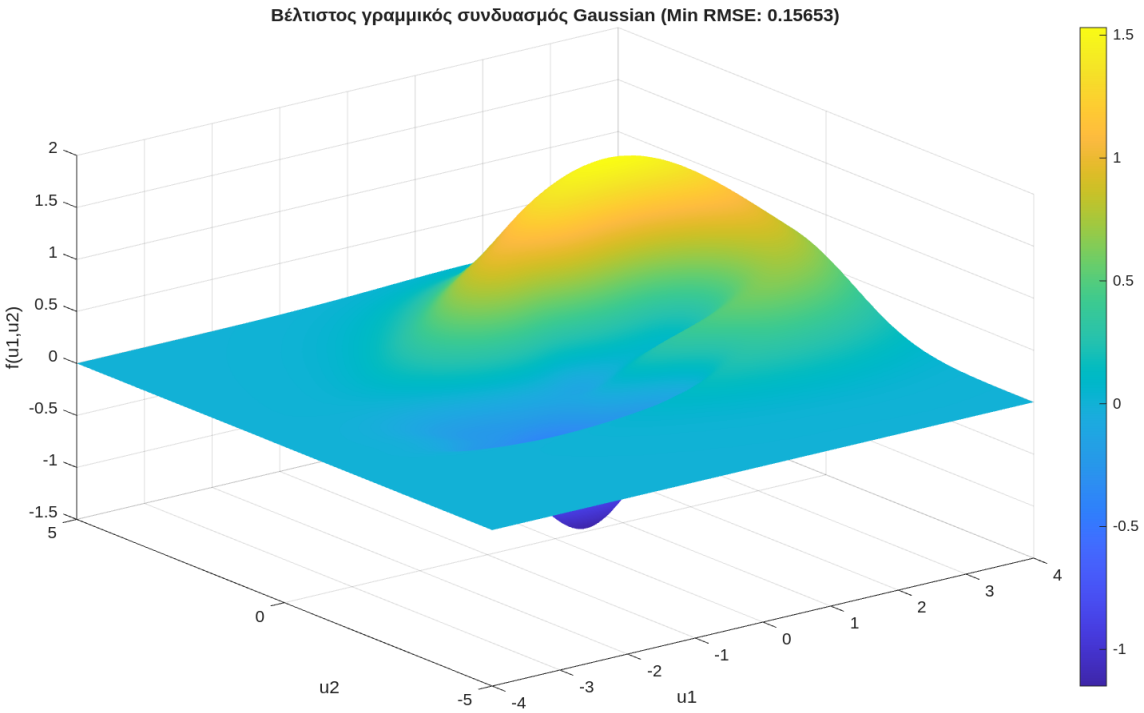

Σχήμα 8: Γραφική παράσταση βέλτιστης προσέγγισης της f σε σύνολο εισόδου μεγαλύτερο του Training Data

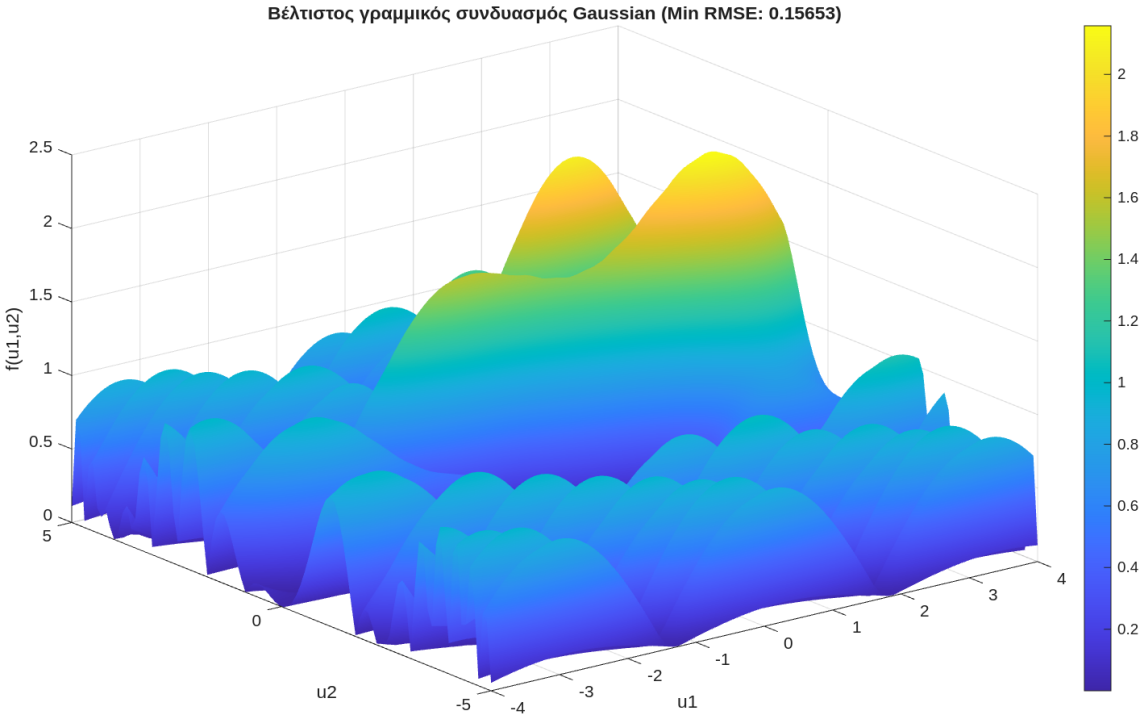

Σχήμα 9: Απόκλιση τιμής βέλτιστης προσέγγισης f και πραγματικής τιμής f σε σύνολο εισόδου μεγαλύτερο από το Training Data

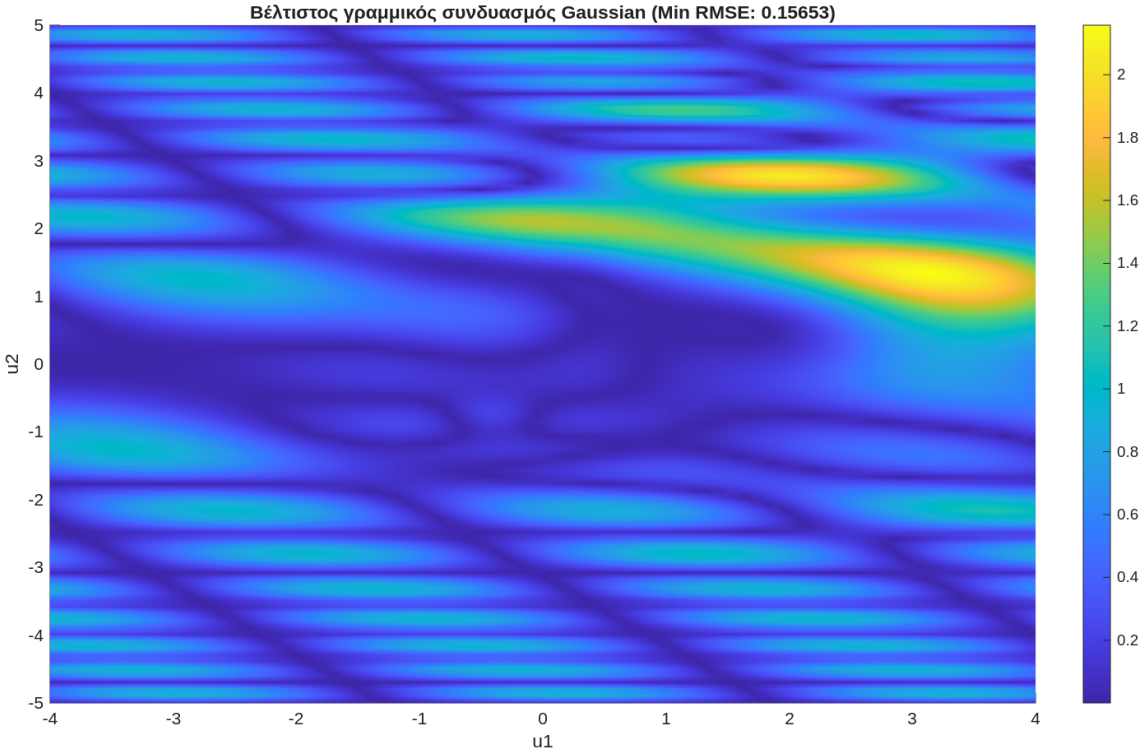

Σχήμα 10: Top View – Απόκλιση τιμής βέλτιστης προσέγγισης f και πραγματικής τιμής f σε σύνολο εισόδου μεγαλύτερο από το Training Data

Από τα παραπάνω δεδομένα συμπεραίνουμε ότι ο γενετικός αλγόριθμος που υλοποιήθηκε παρουσιάζει ικανοποιητική απόδοση εντός του εύρους των δεδομένων εκπαίδευσης, με ελάχιστο σφάλμα RMSE της τάξης του 0.15653. Ωστόσο, η επέκταση του πεδίου ορισμού σε ευρύτερο εύρος τιμών για $u_1 \in [-4, 4]$ και $u_2 \in [-5, 5]$ αναδεικνύει τους περιορισμούς της μεθόδου. Όπως φαίνεται στα διαγράμματα απόκλισης, η διαφορά μεταξύ της βέλτιστης προσέγγισης και της πραγματικής συνάρτησης f ελαχιστοποιείται στην περιοχή όπου εκπαιδεύτηκε το μοντέλο (training data), ενώ αυξάνεται σε περιοχές εκτός αυτού του εύρους. Παρόμοια συμπεριφορά παρατηρείται και σε δοκιμές με διαφορετικά όρια τιμών. Αξιοσημείωτο είναι, ωστόσο, ότι η απόκλιση δεν ξεπερνά την τιμή 2, γεγονός που υποδηλώνει σχετικά ομοιόμορφη συμπεριφορά του μοντέλου, η οποία οφείλεται τόσο στην τριγωνομετρική φύση της συνάρτησης f, όσο και στα βάρη των γκαουσιανών συναρτήσεων.

6 Συμπεράσματα

Στην παρούσα εργασία υλοποιήθηκε ένας γενετικός αλγόριθμος για την προσέγγιση της άγνωστης συνάρτησης $f(u_1, u_2) = \sin(u_1 + u_2)\sin(u_2^2)$ μέσω γραμμικού συνδυασμού 15 Gaussian συναρτήσεων βάσης. Ο αλγόριθμος εφαρμόστηκε σε πληθυσμό 50 υποψήφιων λύσεων, χρησιμοποιώντας τεχνικές ελιτισμού, Tournament Selection, single-point crossover και point mutation για τη βελτιστοποίηση των παραμέτρων.
Τα αποτελέσματα επιβεβαιώνουν την αποτελεσματικότητα της μεθόδου εντός του πεδίου εκπαίδευσης, με την απόκλιση από την πραγματική συνάρτηση να κυμαίνεται στο διάστημα $[0, 0.9]$.
Ωστόσο, η επέκταση του πεδίου ορισμού σε ευρύτερο εύρος τιμών αναδεικνύει τους περιορισμούς του μοντέλου στη γενίκευση εκτός της περιοχής εκπαίδευσης. Όπως φαίνεται στα σχετικά διαγράμματα απόκλισης, το σφάλμα ελαχιστοποιείται στην περιοχή των Training Data, ενώ αυξάνεται σημαντικά εκτός αυτού του εύρους.
Συμπερασματικά, ο γενετικός αλγόριθμος αποδεικνύεται αποτελεσματικό εργαλείο για την προσέγγιση άγνωστων συναρτήσεων μέσω γραμμικού συνδυασμού συναρτήσεων βάσης, με ικανοποιητική απόδοση εντός του πεδίου εκπαίδευσης.
Η μέθοδος επιβεβαιώνει τα πλεονεκτήματα των γενετικών αλγορίθμων που αναφέρθηκαν στη θεωρία, ιδίως την ικανότητα επίλυσης προβλημάτων με μεγάλο πλήθος παραμέτρων χωρίς

απαίτηση υπολογισμού παραγώγων. Η εξάρτηση της ακρίβειας από το πεδίο εκπαίδευσης υπογραμμίζει τη σημασία της επιλογής αντιπροσωπευτικών δεδομένων για την επιτυχή εφαρμογή της μεθόδου. Εξίσου σημαντικό ρόλο έχει η επιλογή παραμέτρων, όπως το μέγεθος του πληθυσμού, η πιθανότητα μετάλλαξης και η μέθοδος διασταύρωσης, γεγονός που απαιτεί εκτενή πειραματισμό για την επίτευξη βέλτιστων αποτελεσμάτων. Τέλος, το υπολογιστικό κόστος αυξάνεται με αυστηρότερα κριτήρια σύγκλισης, καθώς ο αλγόριθμος απαιτεί μεγάλο πλήθος επαναλήψεων για να επιτύχει στόχο min(RMSE) < 0.1.

7 Βιβλιογραφία

Αναφορές

[1] Μέθοδοι Βελτιστοποίησης, CIV1756, *Genetic Algorithms (GA)*, Αναρτημένο εκπαιδευτικό υλικό στην πλατφόρμα eClass του Πανεπιστημίου Πατρών, 2025.
https://eclass.upatras.gr/modules/document/file.php/CIV1756/2-Genetic%20Algorithms%20%28GA%29.pdf

[2] Tutorials Point, *Genetic Algorithms Tutorial*, 2025.
https://www.tutorialspoint.com/genetic_algorithms/index.htm

[3] Spiceworks, *What Are Genetic Algorithms?*, 2025.
https://www.spiceworks.com/tech/artificial-intelligence/articles/what-are-genetic-algorithms/